

# 位姿图优化公式推导

## 一、李群李代数知识回顾




图 1: 李群李代数

### 1. 指数映射关系

#### (a) 三维旋转:

$$\begin{cases} \phi = \ln(R)^\vee \\ R = \exp\{\phi^\wedge\} \end{cases}$$

#### (b) 三维变换:

$$T = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}, \quad \xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix}, \quad \xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ 0 & 0 \end{bmatrix}$$

$$\begin{cases} \xi = \ln(T)^\vee \\ T = \exp\{\xi^\wedge\} \end{cases}$$

### 2. 伴随性质

#### (a) 引理一: $Rp^\wedge R^T = (Rp)^\wedge$

证明: 任取某向量  $v$ , 有以下关系:

$$Rp^\wedge R^T \vec{v}$$

$$= Rp \times R^T \vec{v} \quad (\wedge \text{的定义为向量叉乘的结果})$$

$$= Rp \times RR^T \vec{v} \quad (R \text{ 作为旋转矩阵, 因此 } Rp \times Rv = (\det R)R^{-T}(p \times v) = Rp \times v)$$

$$= Rp \times \vec{v} \quad (R \text{ 作为旋转矩阵, 有 } RR^T = I)$$

$$= Rp^\wedge \vec{v} \quad (\wedge \text{的定义为向量叉乘的结果})$$

**(b) 引理二：**  $\text{Rexp}\{\hat{\mathbf{p}}\}\mathbf{R}^T = \exp\{(\mathbf{R}\mathbf{p})^\wedge\}$

证明：

$$\begin{aligned} & \text{Rexp}\{\hat{\mathbf{p}}\}\mathbf{R}^T \\ &= \mathbf{R} \sum_{k=0}^{\infty} \frac{(\hat{\mathbf{p}})^k}{k!} \mathbf{R}^T \quad (\text{将指数部分泰勒展开}) \\ &= \sum_{k=0}^{\infty} \frac{(\mathbf{R}\hat{\mathbf{p}}\mathbf{R}^T)^k}{k!} \quad (\text{作为旋转矩阵, 有}\mathbf{R}\mathbf{R}^T = \mathbf{I}) \\ &= \sum_{k=0}^{\infty} \frac{(\mathbf{R}\mathbf{p})^k}{k!} \quad (\text{引理一}) \end{aligned}$$

**(c) SE(3) 上的伴随性质：**  $\text{Texp}\{\hat{\xi}\}\mathbf{T}^{-1} = \exp\{(\text{Ad}(\mathbf{T})\xi)^\wedge\}$

其中,

$$\text{Ad}(\mathbf{T}) = \begin{bmatrix} \mathbf{R} & t^\wedge \mathbf{R} \\ 0 & \mathbf{R} \end{bmatrix}$$

证明：

$$\begin{aligned} & \text{Texp}\{\hat{\xi}\}\mathbf{T}^{-1} \\ &= \sum_{k=0}^{\infty} \frac{(\mathbf{T}\hat{\xi}\mathbf{T}^{-1})^k}{k!} \quad (\text{同引理二的证明, 将指数部分泰勒展开}) \\ &= \exp\{\mathbf{T}\hat{\xi}\mathbf{T}^{-1}\} \quad (\text{通过泰勒展开还原回指数形式}) \end{aligned}$$

其中, 指数部分有:

$$\begin{aligned} & \mathbf{T}\hat{\xi}\mathbf{T}^{-1} \\ &= \begin{bmatrix} \mathbf{R} & t \end{bmatrix} \begin{bmatrix} \hat{\phi} & \rho \end{bmatrix} \begin{bmatrix} \mathbf{R}^T & -\mathbf{R}^T t \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R}\hat{\phi}\mathbf{R}^T & -\mathbf{R}\hat{\phi}\mathbf{R}^T t + \mathbf{R}\rho \\ 0 & 0 \end{bmatrix} \\ &= \begin{bmatrix} (\mathbf{R}\hat{\phi})^\wedge & -(\mathbf{R}\hat{\phi})^\wedge t + \mathbf{R}\rho \\ 0 & 1 \end{bmatrix} \quad (\text{使用两次引理一}) \\ &= \begin{bmatrix} (\mathbf{R}\hat{\phi})^\wedge & (\mathbf{R}\hat{\phi})^\wedge t + \mathbf{R}\rho \\ 0 & 1 \end{bmatrix} \quad (\text{右上角的}^\wedge \text{是反对称矩阵的意义, 满足: } a^\wedge b = -b^\wedge a) \\ &= \begin{bmatrix} (\mathbf{R}\hat{\phi})^\wedge t + \mathbf{R}\rho \\ \mathbf{R}\hat{\phi} \end{bmatrix}^\wedge \quad (\text{这里的}^\wedge \text{是对于}\hat{\xi} \text{拓展后的意思}) \\ &= \begin{bmatrix} \mathbf{R} & t^\wedge \mathbf{R} \\ 0 & \mathbf{R} \end{bmatrix} \begin{bmatrix} \hat{\phi} \\ \rho \end{bmatrix}^\wedge = (\text{Ad}(\mathbf{T})\xi)^\wedge \quad (\text{进行矩阵分解, 并带回 Ad(T) 和}\xi) \end{aligned}$$

因此, 带回得到

$$\begin{aligned} & \text{Texp}\{\hat{\xi}\}\mathbf{T}^{-1} \\ &= \exp\{\mathbf{T}\hat{\xi}\mathbf{T}^{-1}\} \\ &= \exp\{(\text{Ad}(\mathbf{T})\xi)^\wedge\} \end{aligned}$$

### 3.BCH 近似公式

(a) 存在一个微扰的情况:  $\ln(\exp\{\xi_1\}\exp\{\xi_2\})^\sim = J_l(\xi_2)^{-1}\xi_1 + \xi_2$ , 其中 $\xi_1$ 为小量

(b) 对微扰求逆运算:  $\exp\{\xi\}\exp\{-\xi\} = \exp\{\xi - \xi\} = I$ , 因此 $\exp\{\xi\}$ 的逆是 $\exp\{-\xi\}$

## 二、位姿图优化公式推导

理论运动位姿关系: 对于估计 $T_i$ 到 $T_j$ 的运动位姿关系为:  $\Delta T_{ij} = T_i^{-1}T_j$ , 移项整理, 得到

$$0 = \ln(T_{ij}^{-1}T_i^{-1}T_j)^\sim$$

构建优化误差: 由于误差存在, 上述式子左侧结果很可能不为 0, 因此构建误差:

$$e_{ij} = \ln(T_{ij}^{-1}T_i^{-1}T_j)^\sim$$

为便于求导, 使用李代数表示, 对 $T_i$ 和 $T_i$ 分别加入一个左扰动:

$$\hat{e}_{ij} = \ln(T_{ij}^{-1}\exp\{(\delta\xi_i)^\wedge\}^{-1}\exp\{(\delta\xi_j)^\wedge\}T_i^{-1}T_j)^\sim$$

$$= \ln(T_{ij}^{-1}\exp\{(-\delta\xi_i)^\wedge\}\exp\{(\delta\xi_j)^\wedge\}T_i^{-1}T_j)^\sim \quad (\text{微小扰动求逆的结果为: } \exp\{-\delta\xi^\wedge\})$$

$$= \ln(T_{ij}^{-1}T_i^{-1}T_j\exp\{(-Ad(T_j^{-1})\delta\xi_i)^\wedge\}\exp\{(-Ad(T_j^{-1})\delta\xi_j)^\wedge\})^\sim$$

(使用两次李代数伴随性质的变式:  $T\exp\{\xi^\wedge\} = \exp\{(Ad(T)\xi)^\wedge\}T$ , 将含 T 部分提前)

$$\approx \ln(T_{ij}^{-1}T_i^{-1}T_j[I - (Ad(T_j^{-1})\delta\xi_i)^\wedge + (Ad(T_j^{-1})\delta\xi_j)^\wedge])^\sim$$

(用 BCH 近似将后两个小量指数部分直接相加, 再对二元函数原点处进行一阶泰勒展开)

值得注意的是, 对数部分是两部分乘积, 前者是 $T_{ij}^{-1}T_i^{-1}T_j$ , 即 $e_{ij}$ ,

后者是关于 ij 的误差, 是一个小量, 记作 $\delta\xi_{ij}$ , 由此通过 BCH 近似

$$\hat{e}_{ij} \approx J_r^{-1}(e_{ij})\ln(\delta\xi_{ij}) + \ln(e_{ij})$$

由此, 我们得到误差的雅各比矩阵:

$$\begin{cases} \frac{\partial \hat{e}_{ij}}{\partial \delta\xi_i} = -J_r^{-1}(e_{ij})Ad(T_j^{-1}) \\ \frac{\partial \hat{e}_{ij}}{\partial \delta\xi_j} = J_r^{-1}(e_{ij})Ad(T_j^{-1}) \end{cases}$$

后续内容在书中就比较清晰了, 分别是对 $J_r^{-1}(e_{ij})$ 进行近似, 并将问题彻底转化成了一个最小二乘问题, 因此就不加赘述了。